Observatório Climático Local: Desenho da Solução de Dados (Pré-Implementação)

Aluno: Fernando da Conceição Cordeiro Filho · **Professora:** Vangela Tatiana Madalena Banhos
Data: Novembro de 2026 · **Repositório:** github.com/SAGIEV007/observatorio-climatico-local

1. Contextualização, Alinhamento com a AE1 e Recorte do Projeto

Problema e justificativa extensionista. Na agricultura familiar de Marília-SP, decisões de manejo (janela de semeadura, turnos de irrigação complementar e proteção de canteiros) dependem criticamente do comportamento da chuva e da temperatura. Embora existam dados públicos robustos, eles chegam em formato técnico complexo (grades de reanálise, arquivos GRIB/NetCDF, APIs REST especializadas) e sem interpretação local. O *Observatório Climático Local* atua como uma ponte extensionista, transformando dados meteorológicos brutos em indicadores retrospectivos claros sobre o que aconteceu na região, sem fazer previsão do tempo.

Público beneficiário. Pequenos agricultores familiares (hortaliças, café e frutas) e técnicos extensionistas da Casa da Agricultura (CATI/CDRS - SAA/SP) que os orientam no planejamento e manejo de campo.

Recorte do projeto. Município de Marília-SP (latitude −22,2139; longitude −49,9458; grade da API a ~4,4 km da sede com 650 m de elevação), cobrindo rigorosamente 30 dias civis consecutivos (26/09/2026 a 25/10/2026) no fuso local `America/Sao_Paulo`. Três variáveis meteorológicas essenciais: temperatura mínima diária, temperatura máxima diária e precipitação diária acumulada.

Refinamento de limiares (Evolução da AE1). Mantém-se total coerência com o planejamento da AE1, adotando-se dois refinamentos técnicos formais: (a) limiar de 1,0 mm para "dia chuvoso" (padrão climatológico ETCCDI), separando orvalho residual de chuva com real relevância agronômica; (b) limiar de 30,0 °C para "dia de calor" (índice TXge30 do Climpact), servindo como triagem inicial de estresse fisiológico térmico.

2. Dicionário de Dados — Versão 1

Estrutura prevista para a tabela principal do banco DuckDB (`clima_diario`):

Campo	Tipo DuckDB	Descrição e Unidade	Origem	Regra de Preenchimento / Validação
`localidade`	VARCHAR	Nome oficial e UF da localidade ("Marília-SP").	Configuração	**NOT NULL.** String não vazia, padrão `[Cidade]-[UF]`. Componente da PK composta.
`data`	DATE	Data civil do registro no fuso local (AAAA-MM-DD).	API (`time`)	**NOT NULL.** Sem duplicatas; intervalo contínuo de 30 dias (26/09 a 25/10/2026). Componente da PK composta.
`latitude`	DOUBLE	Latitude da sede municipal em graus (−22,2139).	Configuração	**NOT NULL.** Numérico no intervalo [−90,0, 90,0]. Valor fixo de referência WGS84.
`longitude`	DOUBLE	Longitude da sede municipal em graus (−49,9458).	Configuração	**NOT NULL.** Numérico no intervalo [−180,0, 180,0]. Valor fixo de referência WGS84.
`temp_min_c`	DOUBLE	Menor temperatura do ar a 2 m no dia, em °C.	API (`temp_min`)	Faixa regional [−5,0, 45,0] °C. Regra: `temp_min_c <= temp_max_c`. Admite NULL (sem troca por 0); cobertura mínima de 90%.
`temp_max_c`	DOUBLE	Maior temperatura do ar a 2 m no dia, em °C.	API (`temp_max`)	Faixa regional [−5,0, 45,0] °C. Regra: `temp_max_c >= temp_min_c`. Admite NULL (sem troca por 0); cobertura mínima de 90%.
`precip_mm`	DOUBLE	Precipitação pluviométrica acumulada em 24h, em mm.	API (`precip_sum`)	**CHECK (precip_mm >= 0).** Faixa [0,0, 400,0] mm. Admite NULL em falha (nunca imputar 0); cobertura mínima de 90%.
`arquivo_origem`	VARCHAR	Nome do arquivo JSON bruto original preservado em disco.	Metadados	**NOT NULL.** Garante proveniência e auditabilidade científica (*data lineage*).
`coletado_em`	TIMESTAMP	Data/hora exata da requisição à API em UTC.	Metadados	**NOT NULL.** Padrão ISO 8601 com confirmação HTTP 200.

3. Modelo Lógico do Banco DuckDB — Versão 1

Estrutura relacional e decisões de arquitetura. O banco armazena os dados no arquivo colunar `dados/observatorio.duckdb`. A modelagem baseia-se na tabela única de fatos climáticos `clima_diario`, concebida para maximizar a performance em consultas analíticas de agregação temporal (OLAP):

```
CREATE TABLE IF NOT EXISTS clima_diario (
    localidade      VARCHAR   NOT NULL,
    data            DATE      NOT NULL,
    latitude        DOUBLE    NOT NULL,
    longitude       DOUBLE    NOT NULL,
    temp_min_c      DOUBLE,
    temp_max_c      DOUBLE,
    precip_mm       DOUBLE    CHECK (precip_mm >= 0),
    arquivo_origem  VARCHAR   NOT NULL,
    coletado_em     TIMESTAMP NOT NULL,
    PRIMARY KEY (localidade, data),
    CHECK (temp_min_c <= temp_max_c)
);
```

Chave Primária Composta: Definida por `PRIMARY KEY (localidade, data)`, garantindo a unicidade unívoca de cada registro por município e data civil.

Chaves Estrangeiras (FK) e Relacionamentos: Não existem chaves estrangeiras nem tabelas secundárias nesta versão 1. Como o DuckDB é um motor de processamento analítico colunar embutido, a desnormalização controlada em tabela única elimina a sobrecarga de operações de `JOIN`, reduz a complexidade operacional de distribuição do arquivo e maximiza a velocidade de varreduras vetoriais no painel Streamlit.

Regra contra registros duplicados: A garantia contra duplicatas ocorre de forma idempotente via SQL: o carregamento utiliza a instrução `INSERT OR REPLACE INTO clima_diario ...`. Reexecuções atualizam os dados existentes sem acrescentar linhas espúrias, mantendo a base estritamente travada em 30 registros (validado em `evidencias/04_carga_repetida.txt`).



Figura 1. Modelo lógico da tabela `clima_diario` no DuckDB: especificação de atributos, tipos colunares, chaves primárias e salvaguardas de integridade.

3.2. Fluxo Simples da Solução (Pipeline E2E)

O pipeline de engenharia de dados é linear, determinístico e auditável, estruturado em 6 etapas integradas: (1) Ingestão HTTP GET com retry exponencial; (2) Tratamento tabular e Quality Gate no Pandas; (3) Carga idempotente colunar no DuckDB; (4) Motor SQL analítico de KPIs; (5) Apresentação interativa em Streamlit; (6) Comunicação extensionista e devolutiva comunitária.

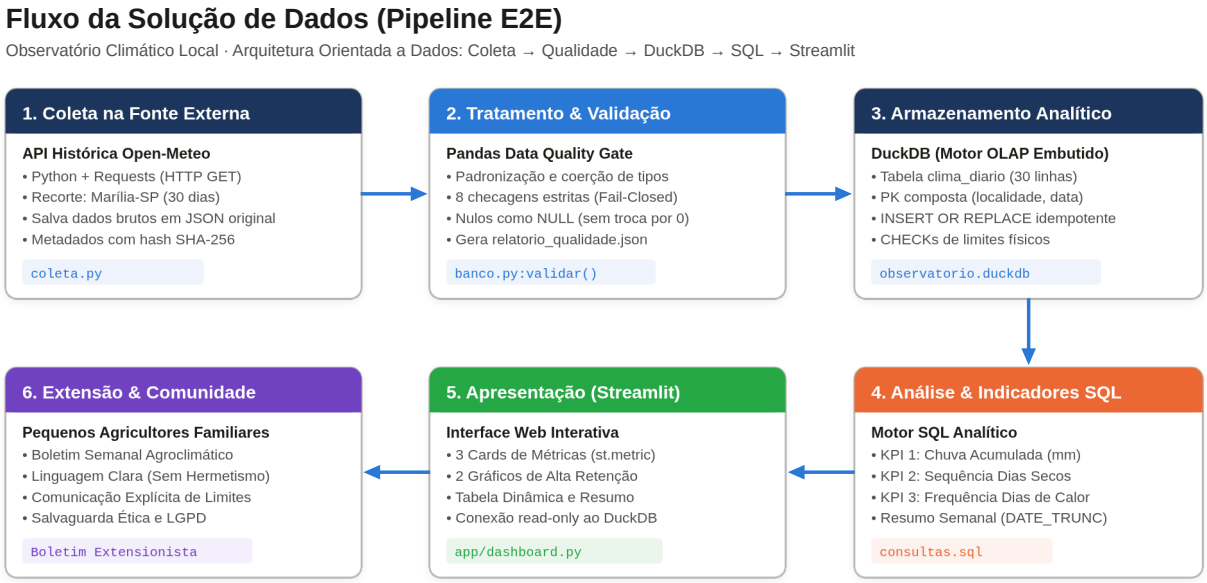


Figura 2. Fluxo ponta a ponta da solução de dados: Coleta (Requests) → Tratamento & Qualidade (Pandas) → Armazenamento (DuckDB) → Análise (SQL) → Apresentação (Streamlit) → Extensão Rural.

4. Plano de Qualidade dos Dados — Checagens Formais

O plano adota a política *fail-closed*: qualquer anomalia física ou estrutural classificada como `ERRO` interrompe imediatamente o pipeline e impede a gravação no banco, gerando relatório de auditoria detalhado em `dados/tratados/relatorio_qualidade.json`.

Checagem	Campo(s)	Regra ou Teste	Ação em Caso de Falha
1. Completude temporal	`data`	Todas as 30 datas presentes, sem lacunas: `len(datas) == 30`.	**Interrompe (ERRO).** Bloqueia carga no DuckDB; notifica quebra no intervalo.
2. Unicidade de datas (PK)	`localidade`, `data`	Ausência de duplicatas: `datas.duplicated().sum() == 0`.	**Interrompe (ERRO).** Bloqueia ingestão para evitar distorção aditiva (`SUM`).
3. Consistência física térmica	`temp_min_c`, `temp_max_c`	Mínima menor ou igual à máxima: `(temp_min_c > temp_max_c).sum() == 0`.	**Interrompe (ERRO).** Bloqueia a carga por inconsistência termodinâmica.
4. Não-negatividade da chuva	`precip_mm`	Precipitação diária não-negativa: `(precip_mm < 0).sum() == 0`.	**Interrompe (ERRO).** Bloqueia a carga; chuva negativa viola a física do dado.
5. Plausibilidade térmica	`temp_min_c`, `temp_max_c`	Valores contidos na faixa regional: [−5,0, 45,0] °C.	**AVISO** se > 40 °C. **ERRO** se extrapolar faixa; dados espúrios viram NULL.
6. Plausibilidade pluviométrica	`precip_mm`	Chuva diária contida na faixa física: [0,0, 400,0] mm.	**Interrompe (ERRO)** se > 400 mm (recorde histórico em SP); rejeita ruído.
7. Cobertura e ausentes	`temp_min_c`, `temp_max_c`, `precip_mm`	Cobertura válida mínima de 90%: `(1 - ausentes / total) >= 0.90`.	Se >= 90%, **nulos ficam como NULL** (nunca 0). Se < 90%, **interrompe (ERRO)**.
8. Integridade criptográfica	Arquivo JSON original	Conferência de hash: `sha256(arquivo) == metadados["sha256"]`.	**Interrompe (ERRO).** Detecta corrupção ou adulteração do arquivo bruto.

5. Plano de Análise e Produto Final

5.1. Relação entre Perguntas Analíticas, Indicadores e Visuais

Pergunta Analítica (AE1)	Campos	Cálculo / Consulta Planejada	Indicador e Unidade	Gráfico / Tabela e Utilidade Extensionista
P1. Quanto choveu e como a chuva se distribuiu?	`data`, `precip_mm`	`SUM(precip_mm)` total; contagem com `FILTER (WHERE precip_mm >= 1)` e `>= 10`; % em temporais.	**KPI 1:** Chuva acumulada (**171,5 mm** em 18 dias).	Gráfico de barras diário e tabela semanal. Apoia época de semeadura e proteção de canteiros contra erosão.
P2. Qual o maior período sem chuva relevante?	`data`, `precip_mm`	Agrupamento de dias secos (< 1 mm) via window function: `data - ROW_NUMBER() OVER (ORDER BY data)`.	**KPI 2:** Maior sequência seca (**5 dias**: 17/10 a 21/10).	Card de destaque e faixa no gráfico de chuva. Ajuda a dimensionar irrigação de mudas e canteiros.
P3. Com que frequência o calor pediu atenção?	`data`, `temp_min_c`, `temp_max_c`	`COUNT(*) FILTER (WHERE temp_max_c >= 30)` (TXge30); amplitude térmica `AVG(max - min)`.	**KPI 3:** Frequência de calor (**7 dias**; 23,3% do tempo).	Gráfico de faixas térmicas diárias com linha de 30 °C. Planejamento de sombreamento e horários no campo.

Detalhamento Técnico Formal dos Indicadores (KPIs)

KPI 1: Chuva Acumulada no Período

• **Definição:** Volume total acumulado de água precipitada na localidade ao longo dos 30 dias civis do recorte.
• **Forma de Cálculo:** Agregação SQL: `ROUND(SUM(precip_mm), 1)`. Métricas complementares: contagem de dias com chuva útil (`precip_mm >= 1`) e proporção percentual concentrada em dias de chuva pesada (`precip_mm >= 10`).
• **Unidade:** Milímetros de precipitação pluviométrica (mm).
• **Tratamento de Ausentes:** A agregação `SUM` ignora nativamente valores `NULL` sem distorção. Mínimo de 90% de cobertura válida exigida pelo Quality Gate. É terminantemente proibida a imputação de zero em dias ausentes.
• **Interpretação Esperada:** Registraram-se **171,5 mm em 18 dias chuvosos**. Contudo, **62,6% do total concentrou-se em apenas 5 dias com chuva forte (>= 10 mm)**, sendo 82,9 mm nos últimos 4 dias (22 a 25/10). O volume foi abundante, porém mal distribuído, alertando para riscos de lixiviação de adubo e erosão superficial.

KPI 2: Maior Sequência de Dias Secos (CDD / Veranico)

• **Definição:** Número máximo de dias civis consecutivos em que a precipitação permaneceu estritamente abaixo do limiar agronômico de 1,0 mm (índice *Consecutive Dry Days* - CDD do ETCCDI).
• **Forma de Cálculo:** Algoritmo de *islands and gaps* via Window Function no DuckDB: `data - CAST(ROW_NUMBER() OVER (ORDER BY data) AS INTEGER) AS sequencia`, agrupando e selecionando a sequência máxima.
• **Unidade:** Dias civis consecutivos (dias).
• **Tratamento de Ausentes:** Ocorrência de valor `NULL` encerra a contagem da sequência de dias secos no dia anterior, impedindo que lacunas na base sejam falsamente computadas como estiagem.
• **Interpretação Esperada:** A maior sequência seca em Marília foi de **5 dias consecutivos (17/10 a 21/10/2026)**, acompanhada de elevação de temperatura máxima (24,9 a 29,7 °C) e encerrada pela tempestade de 22/10. O resultado indica ausência de veranico severo ou déficit hídrico prolongado para as lavouras da região.

KPI 3: Frequência de Dias de Calor Excessivo (TXge30)

• **Definição:** Número total e porcentagem de dias em que a temperatura máxima do ar atingiu ou superou 30,0 °C (índice TXge30 do Climpact), acrescido da amplitude térmica média diária.
• **Forma de Cálculo:** Consulta SQL colunar: `COUNT(*) FILTER (WHERE temp_max_c >= 30)`, percentual sobre o total de dias válidos e média de amplitude diária via `AVG(temp_max_c - temp_min_c)`.
• **Unidade:** Dias civis, porcentagem do período (%) e graus Celsius (°C).
• **Tratamento de Ausentes:** Dias com temperatura máxima ausente são excluídos do numerador e do denominador da porcentagem, restringindo a métrica às observações termicamente válidas.
• **Interpretação Esperada:** Ocorreram **7 dias de calor (23,3% do período)**, sendo que **5 dias ocorreram em bloco consecutivo entre 26 e 30 de setembro** (pico de 33,2 °C em 29/09). A amplitude média foi de 9,2 °C. O período exigiu reforço na irrigação de hortaliças sensíveis e sombreamento em estufas.

5.2. Wireframe do Dashboard Streamlit

Arquitetura de Apresentação e Interação. O painel foi concebido para entregar leitura imediata sem ambiguidades a produtores e extensionistas rurais, priorizando clareza em computadores e celulares:

- **Painel Lateral de Configuração (Sidebar):** Filtros territoriais de sede municipal e coordenadas geográficas, seletor de datas, sliders dinâmicos para calibração de limiares agroclimáticos (calor em 30 °C e chuva útil em 1,0 mm), status da conexão local com o DuckDB (read-only) e hash SHA-256 verificado.
- **Cards Executivos de Indicadores (Métricas):** Destaque visual em 3 colunas dos KPIs primários (Chuva Acumulada: 171,5 mm; Sequência Seca: 5 dias; Dias de Calor: 7 dias / 23,3%) com subrótulos de interpretação e apoio à decisão.
- **Painel Gráfico Sincronizado:** Dois gráficos temporais independentes com grade alinhada (Gráfico 1: variação térmica diária conectando mínima e máxima com linha de alerta em 30 °C; Gráfico 2: precipitação diária acumulada com marcação de temporais ≥ 10 mm e da sequência seca de 5 dias).
- **Tabela Interativa e Resumo Semanal:** Abas dinâmicas permitindo inspecionar tanto a série histórica completa de 30 dias quanto o resumo semanal consolidado (segunda a domingo), base para a confecção de boletins agroclimáticos de extensão.
- **Rodapé Metodológico e Expansor de Limitações:** Atribuição transparente da fonte Open-Meteo (licença CC BY 4.0), especificação clara das unidades físicas (°C, mm, dias) e advertência explícita sobre a natureza retrospectiva dos dados.

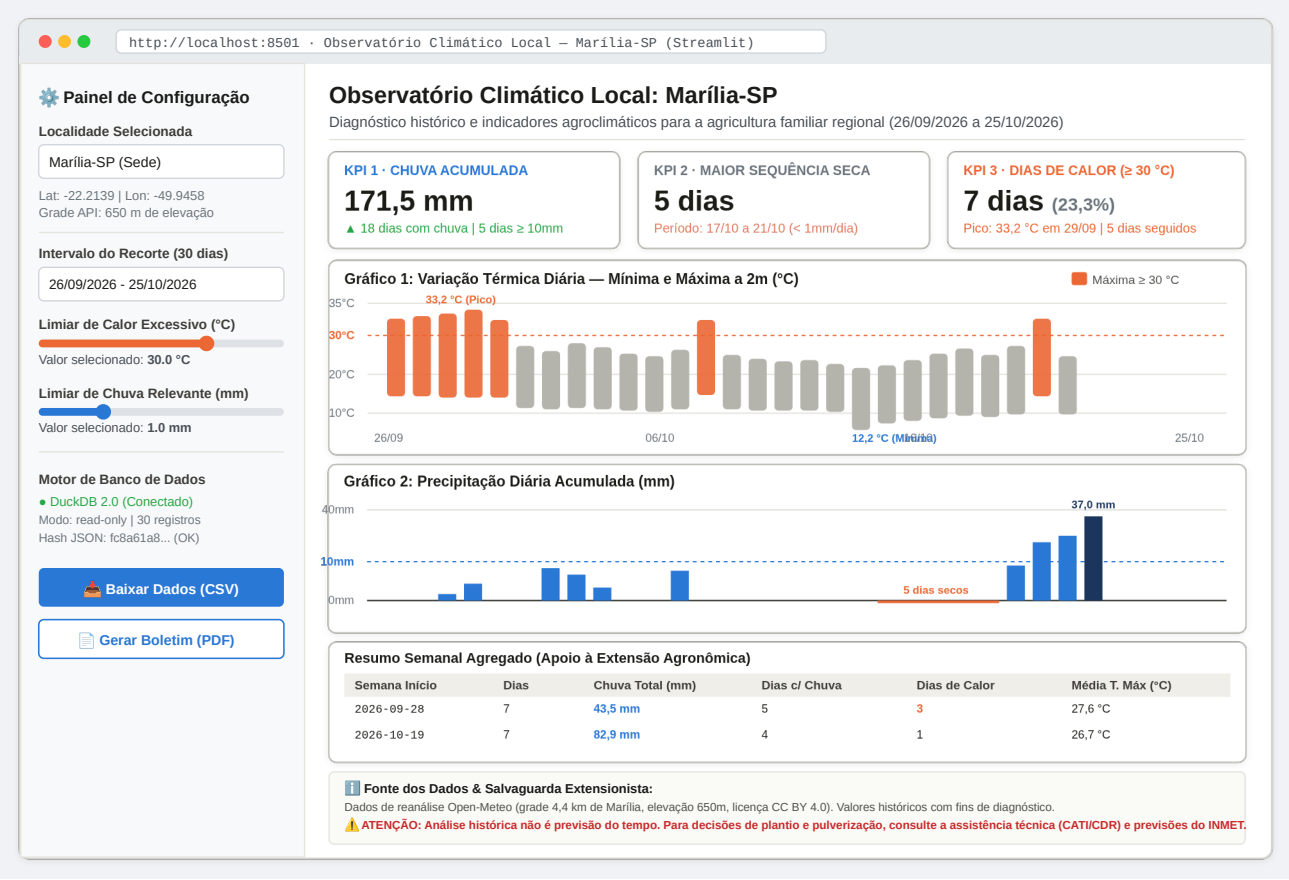


Figura 3. Wireframe completo do dashboard Streamlit: barra lateral de filtros, cards executivos de KPIs, dois gráficos sincronizados, resumo semanal e rodapé metodológico com salvaguardas.

Validação e Protótipo Executável: O desenho técnico encontra-se implementado e auditado no script `app/dashboard_prototipo.py`, operando diretamente sobre o banco `dados/observatorio.duckdb` em modo somente leitura (read-only).

5.3. Comunicação Extensionista e Salvaguardas Éticas

A. Apoio à necessidade identificada na AE1: O painel permite ao produtor confrontar o manejo praticado na lavoura com o balanço hídrico real do período, compreendendo que chuvas concentradas (como os 82,9 mm nos últimos 4 dias) exigem conservação de solo e escalonamento de drenagem, e não apenas celebração de volume total.

B. Linguagem acessível e sem hermetismo: Termos meteorológicos complexos (CDD, TXge30, R10mm) são convertidos em conceitos práticos: *"Dias seguidos sem chuva"*, *"Dias de calor forte (>= 30 °C)"* e *"Chuva forte acumulada"*, acompanhados de convenção semafórica intuitiva e do modelo de *Boletim Semanal Agroclimático* de 1 página impresso e digital.

C. Limitações técnicas comunicadas com rigor: A comunicação deixa claro que os dados derivam de modelo de reanálise atmosférica por grade espacial (~4,4 km de distância da sede), podendo haver divergências com pluviômetros de propriedades específicas. Além disso, testes de sensibilidade entre modelos (ERA5 Best Match vs. ERA5 Seamless) registraram variação de 13% no acumulado (171,5 mm vs. 149,2 mm), evidenciando que os números devem ser lidos como ordens de grandeza referencial, e não precisão micrométrica.

D. Salvaguarda contra recomendações indevidas: Fica formalmente estabelecido em cabeçalhos e telas que **análise histórica não é previsão do tempo**. O painel é estritamente descritivo: decisões agronômicas de plantio, adubação e defensivos devem ser balizadas por agrônomos da CATI/CDRS e previsões meteorológicas oficiais em tempo real (INMET/CIIAGRO).

E. Privacidade e Conformidade com a LGPD: A base utiliza apenas dados climáticos públicos. Dados de produtores rurais em etapas futuras dependerão de termo de consentimento prévio e anonimização (Lei 13.709/2018), permanecendo fora do controle de versão (`dados/comunidade/` no `.gitignore`).

6. Atualização do GitHub e Roadmap de Implementação Futura

O repositório no GitHub (`github.com/SAGIEV007/observatorio-climatico-local`) encontra-se estruturado com pastas padronizadas, templates de issues em `.github/` e 6 issues técnicas detalhadas em `docs/escopo-1/AE2-2/issues/` e consolidadas no arquivo `ISSUES.md`:

```
observatorio-climatico-local/
├── .github/ISSUE_TEMPLATE/     # Templates padronizados de tarefas
├── app/dashboard_prototipo.py   # Protótipo Streamlit (read-only DuckDB)
├── dados/                       # originais/ (JSON bruto), tratados/ (CSV) e observatorio.duckdb
├── docs/escopo-1/AE2-2/         # Relatório formal (PDF e MD), diagramas, wireframe e 6 issues
├── evidencias/                  # Logs auditados de coleta, qualidade, carga e consultas
├── testes/                      # Suite de testes automatizados (19 testes unitários)
├── banco.py | coleta.py | config.py | consultas.sql | executar_consultas.py | requirements.txt
└── README.md                    # Documentação mestre e guia de reprodução técnica
```

Issue	Título da Tarefa Planejada	Módulo / Tecnologia	Dependência	Status
#01	Pipeline de Coleta Automatizada e Preservação de JSON Bruto	Ingestão (Requests / Open-Meteo)	Nenhuma	Planejada / Aberta
#02	Módulo de Tratamento, Padronização e Qualidade (Fail-Closed)	Qualidade de Dados (Pandas)	Issue #01	Planejada / Aberta
#03	Camada de Persistência e Armazenamento Analítico Idempotente	Banco Relacional (DuckDB)	Issue #02	Planejada / Aberta
#04	Motor de Consultas Analíticas e Cálculo de Indicadores/KPIs	Análise Analítica (SQL DuckDB)	Issue #03	Planejada / Aberta
#05	Desenvolvimento do Dashboard Interativo de Visualização	Frontend / Interface (Streamlit)	Issue #03, #04	Planejada / Aberta
#06	Módulo de Comunicação Extensionista, Boletins e LGPD	Extensão Rural & LGPD	Issue #04, #05	Planejada / Aberta

Referências Normativas e Bibliográficas: OPEN-METEO. *Historical Weather API Documentation* (Licença CC BY 4.0). open-meteo.com/en/docs/historical-weather-api, 2026. · ETCCDI. *Climate Change Indices: Consecutive Dry Days (CDD) and Heavy Precipitation Days (R10mm)*. OMM/WMO, 2026. · CLIMPACT. *Indices for Climate Extremes: TXge30*. Climpact Consortium, 2026. · DUCKDB FOUNDATION. *DuckDB SQL Reference and Storage Architecture*. duckdb.org, 2026. · BRASIL. *Lei Geral de Proteção de Dados Pessoais (LGPD)*, Lei nº 13.709/2018. Presidência da República, 2018. Resultados derivados da execução registrada em `evidencias/`.